

d : margin

支持向量机：最大化 margin 的线找最好的超平面
将平行线又到的向量叫支持向量

① 训练数据: $(X_1, y_1), \dots, (X_n, y_n)$, 其中 X_i 为向量, y_i 为标签, 标签值仅为 ± 1

② 线性模型 (W, b) : $W^T X + b = 0$ 超平面方程 (类似线性回归的表达式)

$$\text{eg. } X_i = \begin{bmatrix} x_{i1} \\ x_{i2} \\ \vdots \\ x_{in} \end{bmatrix}, W = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_m \end{bmatrix}, b: \text{constant}$$

③ 线性可分: $\Rightarrow \{f(X_i, y_i)\}_{i=1 \sim N}$, 存在 (W, b) , 对 $\forall i=1 \sim N$, 有:

(definition)

$$\begin{cases} y_i = 1, & W^T X_i + b \geq 0 \\ y_i = -1, & W^T X_i + b < 0 \end{cases}$$

$$\text{即: } y_i [W^T X_i + b] \geq 0$$

优化问题:

$$\text{最小化 } \|W\|^2$$

$$\text{限制条件: } y_i [W^T X_i + b] \geq 1$$

在进行下一步前:

Case 1. 对 $W^T X + b = 0$, 若 $a > 0$ 则 $aW^T X + ab$ 与 $W^T X + b$ 表示一个超平面

Case 2. 点到平面的距离公式:

$$\text{平面: } W_1 X_1 + W_2 X_2 + b = 0, \text{ 点: } (X_0, Y_0)$$

$$d = \frac{|W_1 X_0 + W_2 Y_0 + b|}{\sqrt{W_1^2 + W_2^2}}$$

推广: 高维情况下, $W^T X + b = 0, X_0$:

$$d = \frac{\|W^T X_0 + b\|}{\|W\|}$$

① 欲使 margin d 最大：

$$\frac{d}{2} = \frac{|w^T x + b|}{\|w\|}$$

为了使推导更加简单，我们使用 $cancel$ 进

行缩放，可以使 $|w^T x + b| = 1$ ，即：

$$w = aw, b = ab'$$

$$\Rightarrow \frac{d}{2} = \frac{|aw^T x + ab'|}{\|aw\|} = \frac{a|w^T x + b'|}{a\|w\|}$$

$$= \frac{1}{\|w\|}$$


$$\Rightarrow d = \frac{2}{\|w\|}$$

即对于支持向量 X ，欲求最大的 d ，即需要最小化 w^T 。为了方便起见：

$$d = \frac{2}{\|w\|}$$

② 优化 —— 二次规划 (凸优化)

<目标函数>：二次项 (要么无解，要么一个极值)
<限制条件>：一次项



原问题：最小化凸函数 $f(w)$

限制条件： $g_i(w) \leq 0, i=1 \sim K$

$h_i(w) = 0, i=1 \sim M$

对偶问题：

$$\text{其中 } \alpha = \begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_k \end{bmatrix}, \beta = \begin{bmatrix} \beta_1 \\ \vdots \\ \beta_m \end{bmatrix}$$

定义 $L(w, \alpha, \beta) = f(w) + \alpha^T g(w) + \beta^T h(w)$

最优化： $\Theta(\alpha, \beta) = \inf_{w \in \mathbb{R}^n} \{L(w, \alpha, \beta)\}$ → 最小值

限制条件： $\alpha_i \geq 0, i=1 \sim K$ (即 $\alpha \geq 0$)

定理：若 w^* 是原问题的解，而 α^*, β^* 是对偶问题的解，

那么： $f(w^*) \geq \Theta(\alpha^*, \beta^*)$


$$\Theta(\alpha^*, \beta^*) = \inf_{w \in \mathbb{R}^n} \{f(L(w, \alpha^*, \beta^*))\}$$

$$\leq L(w^*, \alpha^*, \beta^*)$$


$$= f(w^*) + \alpha^{*\top} g(w^*) + \beta^{*\top} h(w^*)$$

$$\leq 0 \quad = 0$$

$$\leq f(w^*)$$



最优化中的凸函数



定义: $G = f(w^*) - \mathbb{H}(\alpha^*, \beta^*)$, G 叫原问题与对偶问题的间距

(某些特定优化问题可以证明 $G=0$)

强对偶定理: 若 $f(w)$ 为凸函数, 且 $g(w) = Aw + b$

(暂不证明) $h(w) = Cw + d$

则当对偶间距 $G=0$ 时取得最优条件

R.P. $f(w^*) = \mathbb{H}(\alpha^*, \beta^*)$

前文中, $f(w^*) = f(w^*) + \sum_{i=1}^k \alpha_i^* g_i(w^*)$, 那么必然 $\begin{cases} \alpha_i^* = 0 \text{ 或} \\ g_i(w^*) = 0 \end{cases}$ ← KKT 条件.

在支持向量机中，

$$\text{最小化: } \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i$$

$$\text{限制条件: } \begin{cases} \text{① } y_i [w^\top \varphi(x_i) + b] \geq -\xi_i \\ \text{② } \xi_i \geq 0 \end{cases}$$

原问题 $f(w)$ 为凸函数

$$g_i(w) \leq 0$$

$$h(w) = 0$$

⇒ 改造: 对 ξ_i 取相反数。

$$\text{最小化: } f(w) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i$$

$$\text{限制条件: } \begin{cases} \text{① } 1 + \xi_i - y_i w^\top \varphi(x_i) - y_i b \leq 0 \\ \text{② } \xi_i \leq 0 \end{cases}$$

$$\text{对偶问题: } \text{④}(w, \beta) = \inf_{\substack{\text{subject to} \\ g_i(w, \xi_i, b)}} \left\{ \frac{1}{2} \|w\|^2 - C \sum_{i=1}^N \xi_i + \sum_{i=1}^N \beta_i \xi_i + \sum_{i=1}^N \alpha_i [1 + \xi_i - y_i w^\top \varphi(x_i) - y_i b_i] \right\}$$

$$\text{限制条件: } \begin{cases} \alpha_i \geq 0 \\ \beta_i \geq 0 \end{cases}$$

$$\text{找极值: } \begin{cases} \frac{\partial L}{\partial w} = w - \sum_{i=1}^N \alpha_i y_i \varphi(x_i) = 0 \\ \frac{\partial L}{\partial \xi_i} = -C + \beta_i + \alpha_i = 0 \\ \frac{\partial L}{\partial b} = -\sum_{i=1}^N \alpha_i y_i = 0 \end{cases}$$

$$\Rightarrow w = \sum_{i=1}^N \alpha_i y_i \varphi(x_i) \quad \text{①}$$

$$\alpha_i + \beta_i = C$$

$$\sum_{i=1}^N \alpha_i y_i = 0$$

$$\beta_i = \alpha_i + \beta_i$$

代入 L:

$$L = \frac{1}{2} \|w\|^2 - C \sum_{i=1}^N \xi_i + \sum_{i=1}^N \beta_i \xi_i + \sum_{i=1}^N \alpha_i \xi_i + \sum_{i=1}^N \alpha_i - \sum_{i=1}^N \alpha_i y_i w^\top \varphi(x_i) - \sum_{i=1}^N \alpha_i y_i \cdot b$$

$$\text{由①: } \frac{1}{2} \|w\|^2 = \frac{1}{2} w^\top w = \frac{1}{2} \left(\sum_{i=1}^N \alpha_i y_i \varphi(x_i) \right)^\top \left(\sum_{j=1}^N \alpha_j y_j \varphi(x_j) \right)$$

$$= \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \varphi(x_i)^\top \varphi(x_j)$$

$$\text{对于 } -\sum_{i=1}^N \alpha_i y_i w^\top \varphi(x_i)$$

$$= -\sum_{i=1}^N \alpha_i y_i \left(\sum_{j=1}^N \alpha_j y_j \varphi(x_j) \right)^\top \varphi(x_i)$$

$$= -\sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \varphi(x_i)^\top \varphi(x_j)$$

$$= K(x_i, x_j),$$

是常数

这儿不能代③, 因为每组 $w^\top \varphi(x)$ 不一样,
无法提出为 $w^\top \varphi(x) \sum_{i=1}^N \alpha_i y_i$, 只能写 $\sum_{i=1}^N \alpha_i y_i \varphi(x)$

$$\text{最终: } L(w, \alpha, \beta) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \varphi(x_i)^\top \varphi(x_j)$$

$$\text{即: } \text{④}(\alpha, \beta) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

限制条件: ① $0 < \alpha_i \leq C$ ⇔ 上式得到 $\alpha_i + \beta_i = C, \alpha_i \geq 0, \beta_i \geq 0$.

② $\sum_{i=1}^N \alpha_i y_i = 0$ ⇔ 上式的

已知: 标签 y_1, y_2 , 以及核函数表达式 K . 未知: α .

$$\begin{aligned}
 \text{对于 } W^T \varphi(x) &= \sum_{i=1}^N [\alpha_i y_i \varphi(x_i)]^T \varphi(x) \\
 &= \sum_{i=1}^N \alpha_i y_i \varphi(x_i)^T \varphi(x) = \sum_{i=1}^N \alpha_i y_i K(x_i, x), \text{发现 } w \text{ 不用求} \\
 \text{且用 } \alpha_i^* = 0 \text{ 或 } g_i^* w^* = 0 \text{ (KKT条件), 有:} \\
 \textcircled{1} \quad &\text{要么 } \beta_i = 0, \text{ 要么 } \xi_i = 0 \\
 \textcircled{2} \quad &\text{要么 } \alpha_i = 0, \text{ 要么 } 1 - \xi_i - y_i W^T \varphi(x_i) - y_i b = 0 \\
 &\text{且 } 0 < \alpha_i < C \Rightarrow \beta_i = C - \alpha_i > 0 \\
 &\text{此时, } \beta_i \neq 0 \Rightarrow \xi_i = 0 \\
 &\alpha_i \neq 0 \Rightarrow 1 - \xi_i - y_i W^T \varphi(x_i) - y_i b = 1 - y_i W^T \varphi(x_i) - y_i b = 0 \\
 &\Rightarrow b = \frac{1 - y_i W^T \varphi(x_i)}{y_i} = \frac{1 - y_i \sum_{j=1}^N \alpha_j y_j K(x_i, x_j)}{y_i}
 \end{aligned}$$

测试: 替换 w 即可

$$\Rightarrow \hat{y} \left(\sum_{i=1}^N \alpha_i y_i K(x_i, x) + b \right) \geq 0$$